




CRISP-DM





Comprensión del negocio



- Problema: Un tercio de los alimentos globales se pierde o desperdicia (1.300 millones de toneladas/año, según la FAO), siendo la producción agrícola y la clasificación postcosecha los puntos más críticos.


- Desafío: La clasificación manual es subjetiva, inconsistente y propensa a la fatiga humana.
- Oportunidad: La automatización con visión artificial estabiliza la calidad en altos volúmenes y puede incrementar las ganancias de los productores entre un 30 % y 50%.
- Enfoque: Clasificación en tres niveles de calidad (Bueno, Regular, Malo) alineados con estándares internacionales (OECD / Comisión Europea).





Comprensión de los datos


Distribución de clases en el dataset



Dataset: 27.944 imágenes de Kaggle con 6 tipos de frutas. Distribución inicial: Bueno 51.2%, Malo 32.3% y Regular 16.5%.

Limitaciones detectadas:


- Etiquetado subjetivo: Frontera difusa entre "Bueno" y "Regular" (ej. plátanos con manchas menores mal clasificados). La clase "Malo" es la única totalmente inequívoca.
- Diversidad artificial: El dataset venía inflado con data augmentation previo (rotaciones básicas), lo que no aporta variabilidad real del mundo real (luces, fondos, madurez).
- Fondos irreales: Predominio de fondos blancos de estudio que contrastan con la complejidad de los entornos comerciales reales.



Preparación de los datos

- Filtrado: Limpieza manual para eliminar duplicados exactos, fotos mal expuestas, imágenes con múltiples frutas o bajo contraste.
- Procesamiento: Redimensionamiento a 64 x 64 píxeles con padding blanco para preservar la relación de aspecto de forma eficiente.
- Ingeniería de Características: Extracción de histogramas de color RGB (32 bins), medias y desviaciones estándar, generando un vector de 102 características para los modelos tradicionales.
- Balanceo y División: Uso de SMOTE para balancear la clase minoritaria ("Regular") y división estratificada del dataset en 70% Entrenamiento, 15% Validación y 15% Prueba.

Modelado



Regresión logística

Como línea base. Usamos GridSearch con 3 valores de C (0.1, 1.0, 10.0) con regularización L2 y `class_weight="balanced"` para compensar el desbalance. Validación cruzada de 5 pliegues. Resultado: F1 macro de 0.7363.



Random Forest


Búsqueda en rejilla con 36 combinaciones de hiperparámetros: `n_estimators` (100, 200, 300), `max_depth` (None, 10, 20), `min_samples_split` (2, 5), `max_features` ("sqrt", "log2"). Validación cruzada de 5 pliegues. Resultado: F1 macro de 0.9666, superando ampliamente a la regresión logística.



CNN (Red Neuronal Convolutacional)

Arquitectura de 3 capas convolucionales (32, 64 y 128 filtros) con normalización por lotes, max-pooling, dropout (0.4) y augmentación en tiempo real (volteo horizontal, rotación $\pm 10\%$, contraste aleatorio). Entrenada por 20 épocas con optimizador Adam ($lr=0.001$), batch size 32, y early stopping con paciencia de 5 épocas.

Evaluación y resultados



En el conjunto de prueba (4.192 imágenes), los modelos avanzados mostraron un rendimiento casi idéntico:

- Random Forest: Accuracy: 96.35% | F1: 0.9615
- CNN: Accuracy: 96.35% | F1 0.9605
- Análisis de errores: Ambos modelos cometieron exactamente 153 errores 3.65%, concentrados en las fronteras ambiguas (Bueno vs. Regular / Regular vs. Malo). Esto confirma que el error no es del algoritmo, sino de la subjetividad intrínseca del etiquetado humano.
- Conclusión: Existe una alta capacidad de generalización (brecha de solo 0.5% entre validación y prueba), alineando el proyecto con los estándares de éxito de la literatura científica internacional 90% - 97%.



Despliegue

